

Contrôle continu du 7 Mars 2023
Durée 1h30-Notes de cours et calculatrices autorisées

1 Comparaison de *Loss* en débruitage

Soit n un entier naturel non nul. Pour $i = 1, \dots, n$, on considère des variables indépendantes ε_i . On suppose que ces variables sont centrées et de même variance σ_*^2 . Soit m^* un paramètre inconnu, pour $i = 1, \dots, n$ on observe $Y_i = m^* + \varepsilon_i$. L'objectif est d'estimer le paramètre inconnu m^* .

1. Pour $x \in \mathbb{R}$ et $a \in \mathbb{R}$. a est fixé et on pose

$$P_a(x) = x(x - 2a).$$

- (a) Montrer que l'unique minimum de P_a sur \mathbb{R} est $x = a$.
- (b) On suppose $a \leq 0$. Montrer que l'unique minimum de P_a sur \mathbb{R}^+ est $x = 0$.
- (c) On suppose $a \geq 0$. Montrer que l'unique minimum de P_a sur \mathbb{R}^- est $x = 0$.

2. Pour $m \in \mathbb{R}$, on considère la fonction de perte

$$L_2(m) = \sum_{i=1}^n (Y_i - m)^2, \quad (m \in \mathbb{R}).$$

- (a) Montrer que la fonction L_2 possède un unique minimum sur \mathbb{R} . On appelle \hat{m}_0 ce minimum.
- (b) Montrer que \hat{m}_0 est sans biais ($\mathbb{E}(\hat{m}_0) = m^*$).
- (c) Montrer que son risque quadratique $r_2(\hat{m}_0, m^*) := \mathbb{E}[(\hat{m}_0 - m^*)^2]$ vaut $\text{Var}(\hat{m}_0) = \frac{\sigma_*^2}{n}$.

3. Pour $\lambda > 0$ fixé, on considère maintenant la version *ridge* de la perte L_2 :

$$L_2^{\text{ridge}}(m, \lambda) = \sum_{i=1}^n (Y_i - m)^2 + n\lambda m^2, \quad (m \in \mathbb{R}).$$

- (a) Déterminer l'unique minimiseur \hat{m}_λ de L_2^{ridge} sur \mathbb{R} et montrer qu'il peut s'écrire

$$\hat{m}_\lambda = \hat{m}_0 \left(1 - \frac{\lambda}{1 + \lambda} \right).$$

- (b) Montrer que

$$\begin{aligned} r_2(\hat{m}_\lambda, m^*) &= \mathbb{E}[(\hat{m}_\lambda - \mathbb{E}[\hat{m}_\lambda] + \mathbb{E}[\hat{m}_\lambda] - m^*)^2] \\ &= (\mathbb{E}[\hat{m}_\lambda] - m^*)^2 + \text{Var}(\hat{m}_\lambda) \\ &= \frac{(m^*)^2 \lambda^2}{(1 + \lambda)^2} + \frac{\sigma_*^2}{n} \left(1 - \frac{\lambda}{1 + \lambda} \right)^2 = \frac{(m^*)^2 \lambda^2 + \frac{\sigma_*^2}{n}}{(1 + \lambda)^2}. \end{aligned}$$

La première égalité est générale et est appelée la décomposition biais variance du risque quadratique.
Justifier cette appellation.

4. Pour $\lambda > 0$ fixé, on considère maintenant la version *LASSO* de la perte L_2 :

$$L_2^{\text{LASSO}}(m, \lambda) = \sum_{i=1}^n (Y_i - m)^2 + 2n\lambda|m|, \quad (m \in \mathbb{R}).$$

- (a) Pour $\lambda > 0$ fixé, tracer la courbe représentative sur \mathbb{R} de la fonction $\psi(m) := L_2^{\text{LASSO}}(m, \lambda)$.
- (b) Montrer que le minimiseur de $L_2^{\text{LASSO}}(m, \lambda)$ est

$$\hat{m}_\lambda = \begin{cases} \hat{m}_0 - \lambda & \text{si } \hat{m}_0 > 0 \text{ et } \hat{m}_0 - \lambda > 0, \\ \hat{m}_0 + \lambda & \text{si } \hat{m}_0 < 0 \text{ et } \hat{m}_0 + \lambda < 0, \\ 0 & \text{sinon.} \end{cases}$$

- (c) Quelle est votre intuition sur cet estimateur ?
- (d) Dans quelle circonstance pensez-vous qu'il peut être judicieux de l'utiliser ?

2 Régression linéaire multiple

Dans le plan, on considère les quatre coins C_i , $i = 1, \dots, 4$ du carré centré à l'origine et de côté de longueur 2.

On pose, pour $i = 1, \dots, 4$, $C_i = \begin{pmatrix} x_1^{(i)} \\ x_2^{(i)} \end{pmatrix}$. On considère le modèle linéaire

$$Y^{(i)} = \theta_0^* + \theta_1^* x_1^{(i)} + \theta_2^* x_2^{(i)} + \varepsilon_i, \quad i = 1, \dots, 4.$$

Ici les variables aléatoires ε_i , $i = 1, \dots, 4$ sont i.i.d. de loi $\mathcal{N}(0, \sigma_*^2)$.

1. Écrire le modèle de façon vectorielle (le vecteur d'observation de dimension 4 est $\mathcal{Y} = \begin{pmatrix} Y^{(1)} \\ Y^{(2)} \\ Y^{(3)} \\ Y^{(4)} \end{pmatrix}$ et le paramètre vectoriel de dimension 3 est $\theta^* = \begin{pmatrix} \theta_0^* \\ \theta_1^* \\ \theta_2^* \end{pmatrix}$).
2. Déterminer, en fonction des observations \mathcal{Y} , les estimateurs du maximum de vraisemblance du vecteur θ^* .
3. Déterminer l'estimateur sans biais de σ_*^2